

Parcial Teorico Deep Learning

Santiago Lugo Camacho

Septiembre 2026

1. Entropía cruzada binaria

En clasificación binaria, suponga que la etiqueta verdadera es

$$y \in \{0, 1\},$$

y que el modelo produce una salida

$$\hat{y} \in (0, 1),$$

interpretada como

$$\hat{y} = P(y = 1 \mid x).$$

La función de pérdida de entropía cruzada binaria se define como

$$\mathcal{L}(y, \hat{y}) = -[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})].$$

1.1. Casos particulares

Simplifique la expresión de $\mathcal{L}(y, \hat{y})$ en los dos casos posibles:

- Cuando $y = 1$.
- Cuando $y = 0$.

Explique brevemente qué probabilidad está siendo penalizada en cada caso.

Solución:

a. Caso $y = 1$:

Sustituyendo $y = 1$ en la función de pérdida original:

$$\mathcal{L}(1, \hat{y}) = -[(1) \log(\hat{y}) + (1 - 1) \log(1 - \hat{y})]$$

$$\mathcal{L}(1, \hat{y}) = -[\log(\hat{y}) + 0] = -\log(\hat{y}).$$

b. Caso $y = 0$:

Sustituyendo $y = 0$ en la función de pérdida original:

$$\mathcal{L}(0, \hat{y}) = -[(0) \log(\hat{y}) + (1 - 0) \log(1 - \hat{y})]$$

$$\mathcal{L}(0, \hat{y}) = -[0 + \log(1 - \hat{y})] = -\log(1 - \hat{y}).$$

Explicación de la penalización:

En ambos casos, la función de pérdida penaliza al modelo a medida que la probabilidad predicha asignada se aleja de la clase verdadera de forma exponencial, es decir, entre más se aleja mas duramente se penaliza.

1.2. Cálculo e interpretación numérica

Calcule la pérdida en los siguientes casos:

$$(y, \hat{y}) = (1, 0,9), \quad (y, \hat{y}) = (1, 0,1),$$

$$(y, \hat{y}) = (0, 0,9), \quad (y, \hat{y}) = (0, 0,1).$$

Luego responda:

- ¿En cuáles casos la pérdida es pequeña?
- ¿En cuáles casos la pérdida es grande?
- ¿Qué nos dice esto sobre la forma en que la entropía cruzada castiga predicciones confiadas pero equivocadas?

Solución:

Cálculos de pérdida:

Usando la función de entropía cruzada binaria $\mathcal{L}(y, \hat{y}) = -[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$ con logaritmo natural ($\ln$):

- Para $(y, \hat{y}) = (1, 0,9)$:

$$\mathcal{L}(1, 0,9) = -\ln(0,9) \approx 0,1053$$

- Para $(y, \hat{y}) = (1, 0,1)$:

$$\mathcal{L}(1, 0,1) = -\ln(0,1) \approx 2,3026$$

- Para $(y, \hat{y}) = (0, 0,9)$:

$$\mathcal{L}(0, 0,9) = -\ln(1 - 0,9) = -\ln(0,1) \approx 2,3026$$

- Para $(y, \hat{y}) = (0, 0,1)$:

$$\mathcal{L}(0, 0,1) = -\ln(1 - 0,1) = -\ln(0,9) \approx 0,1053$$

Respuestas a las preguntas:

- a. La pérdida es pequeña ($\approx 0,1053$) en los casos $(1, 0, 9)$ y $(0, 0, 1)$, donde la probabilidad predicha coincide con la etiqueta real.
- b. La pérdida es grande ($\approx 2,3026$) en los casos $(1, 0, 1)$ y $(0, 0, 9)$, donde el modelo predice lo opuesto a la etiqueta real.
- c. Muestra que la penalización crece de forma no lineal (logarítmica). Cuando el modelo está seguro de una respuesta pero se equivoca ($\hat{y} \rightarrow 0$ con $y = 1$ o $\hat{y} \rightarrow 1$ con $y = 0$), la pérdida asume valores altos para obligar al algoritmo a corregir fuertemente sus parámetros.

1.3. Comportamiento en los extremos

Analice qué ocurre con la pérdida cuando

$$\hat{y} \rightarrow 1$$

y cuando

$$\hat{y} \rightarrow 0,$$

para cada uno de los casos $y = 1$ y $y = 0$.

Explique por qué la entropía cruzada penaliza fuertemente asignar probabilidad cercana a cero a la clase verdadera.

Solución:

Análisis de límites por casos:

a. Caso $y = 1$ ($\mathcal{L}(1, \hat{y}) = -\ln(\hat{y})$):

- Si $\hat{y} \rightarrow 1$: $\lim_{\hat{y} \rightarrow 1} (-\ln(\hat{y})) = -\ln(1) = 0$. La pérdida tiende a cero cuando la predicción es correcta y segura.
- Si $\hat{y} \rightarrow 0$: $\lim_{\hat{y} \rightarrow 0^+} (-\ln(\hat{y})) = +\infty$. La pérdida tiende a infinito cuando el modelo predice la clase opuesta con alta confianza.

b. Caso $y = 0$ ($\mathcal{L}(0, \hat{y}) = -\ln(1 - \hat{y})$):

- Si $\hat{y} \rightarrow 1$: $\lim_{\hat{y} \rightarrow 1^-} (-\ln(1 - \hat{y})) = +\infty$. La pérdida tiende a infinito al predecir la clase 1 cuando la real es 0.
- Si $\hat{y} \rightarrow 0$: $\lim_{\hat{y} \rightarrow 0} (-\ln(1 - \hat{y})) = -\ln(1) = 0$. La pérdida tiende a cero cuando la predicción coincide con la etiqueta.

Explicación de la penalización:

La función logarítmica diverge hacia infinito cuando su argumento se aproxima a cero ($\lim_{z \rightarrow 0^+} \ln(z) = -\infty$). Dado que la entropía cruzada mide la pérdida en términos de $-\ln(P(\text{clase correcta}))$, asignar una probabilidad cercana a cero a la clase verdadera

equivale a un grado alto de incertidumbre o un error confiado. Este tipo de penalización genera gradientes mas grandes en el optimizador, forzando un ajuste directo e inmediato en los pesos del modelo para corregir el error.

1.4. Derivada respecto a la predicción

Calcule:

$$\frac{\partial \mathcal{L}}{\partial \hat{y}}.$$

A partir del resultado, explique por qué la derivada puede crecer mucho cuando el modelo asigna una probabilidad muy baja a la clase correcta.

Solución:

Cálculo de la derivada:

Dada la función de pérdida de entropía cruzada binaria:

$$\mathcal{L}(y, \hat{y}) = -[y \ln(\hat{y}) + (1 - y) \ln(1 - \hat{y})]$$

Diferenciando con respecto a $\hat{y}$:

$$\frac{\partial \mathcal{L}}{\partial \hat{y}} = - \left[\frac{y}{\hat{y}} + (1 - y) \frac{-1}{1 - \hat{y}} \right] = -\frac{y}{\hat{y}} + \frac{1 - y}{1 - \hat{y}}$$

Agrupando ambas fracciones sobre un mismo denominador:

$$\frac{\partial \mathcal{L}}{\partial \hat{y}} = \frac{-y(1 - \hat{y}) + (1 - y)\hat{y}}{\hat{y}(1 - \hat{y})} = \frac{-y + y\hat{y} + \hat{y} - y\hat{y}}{\hat{y}(1 - \hat{y})} = \frac{\hat{y} - y}{\hat{y}(1 - \hat{y})}$$

Explicación del comportamiento de la derivada:

Analizando la derivada obtenida $\frac{\partial \mathcal{L}}{\partial \hat{y}} = \frac{\hat{y} - y}{\hat{y}(1 - \hat{y})}$ en los dos casos de asignación de probabilidad baja a la clase correcta:

- Si $y = 1$ y la predicción es muy baja ($\hat{y} \rightarrow 0$):

$$\frac{\partial \mathcal{L}}{\partial \hat{y}} = \frac{\hat{y} - 1}{\hat{y}(1 - \hat{y})} = -\frac{1}{\hat{y}} \xrightarrow{\hat{y} \rightarrow 0} -\infty$$

El denominador $\hat{y}$ se vuelve extremadamente pequeño, haciendo que la magnitud de la derivada tienda a infinito.

- Si $y = 0$ y la predicción es muy alta ($\hat{y} \rightarrow 1$, es decir, asigna probabilidad muy baja $1 - \hat{y} \rightarrow 0$ a la clase 0):

$$\frac{\partial \mathcal{L}}{\partial \hat{y}} = \frac{\hat{y}}{\hat{y}(1 - \hat{y})} = \frac{1}{1 - \hat{y}} \xrightarrow{\hat{y} \rightarrow 1} +\infty$$

El denominador $1 - \hat{y}$ tiende a cero, por lo que la derivada vuelve a tender a infinito.

En ambos casos, cuando la probabilidad asignada a la clase correcta tiende a cero, aparece una indeterminación por división sobre cero. Esto provoca que el gradiente crezca en magnitud, empujando fuertemente la actualización de los parámetros del modelo en la dirección opuesta al error.

1.5. Sigmoide y señal de error

Suponga ahora que la salida del modelo se obtiene aplicando una función sigmoide a un logit z :

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}}.$$

Usando la regla de la cadena, muestre que:

$$\frac{\partial \mathcal{L}}{\partial z} = \hat{y} - y.$$

Puede usar que:

$$\frac{d\sigma}{dz} = \sigma(z)(1 - \sigma(z)).$$

Finalmente, interprete el resultado:

$$\hat{y} - y.$$

¿Qué significa esta cantidad como señal de error en la capa de salida?

Solución:

Demostración por regla de la cadena:

Aplicando la regla de la cadena para la derivada de $\mathcal{L}$ con respecto al logit z :

$$\frac{\partial \mathcal{L}}{\partial z} = \frac{\partial \mathcal{L}}{\partial \hat{y}} \cdot \frac{\partial \hat{y}}{\partial z}$$

Del ejercicio anterior, se tiene que:

$$\frac{\partial \mathcal{L}}{\partial \hat{y}} = \frac{\hat{y} - y}{\hat{y}(1 - \hat{y})}$$

Por la propiedad de la función sigmoide ($\hat{y} = \sigma(z)$):

$$\frac{\partial \hat{y}}{\partial z} = \frac{d\sigma}{dz} = \sigma(z)(1 - \sigma(z)) = \hat{y}(1 - \hat{y})$$

Sustituyendo ambos términos en la regla de la cadena:

$$\frac{\partial \mathcal{L}}{\partial z} = \left(\frac{\hat{y} - y}{\hat{y}(1 - \hat{y})} \right) \cdot (\hat{y}(1 - \hat{y}))$$

Simplificando los términos del denominador con el término de la derivada de la sigmoide:

$$\frac{\partial \mathcal{L}}{\partial z} = \hat{y} - y$$

Interpretación del resultado:

La cantidad $\hat{y} - y$ representa el error residual directo entre la predicción del modelo y la etiqueta real:

- **Señal de error limpia y lineal:** Al combinar la entropía cruzada con la función sigmoide, los términos no lineales de saturación $\hat{y}(1 - \hat{y})$ se cancelan algebraicamente. Esto evita el problema del desvanecimiento del gradiente en la capa de salida.
- **Proporcionalidad del ajuste:** La magnitud del gradiente es directamente proporcional a qué tan alejado está el modelo de la respuesta correcta. Un error grande produce una corrección fuerte sobre los pesos, mientras que un error cercano a cero genera actualizaciones mínimas, asegurando estabilidad en el entrenamiento.

2. Entropía cruzada binaria

Considere ahora un problema de clasificación multiclase con K clases mutuamente excluyentes. La red produce un vector de logits:

$$\mathbf{z} = (z_1, z_2, \dots, z_K).$$

La función softmax transforma estos logits en un vector de probabilidades:

$$\hat{y}_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad k = 1, \dots, K.$$

La etiqueta verdadera se representa mediante un vector one-hot:

$$\mathbf{y} = (y_1, y_2, \dots, y_K),$$

donde

$$y_k \in \{0, 1\}, \quad \sum_{k=1}^K y_k = 1.$$

La entropía cruzada categórica se define como

$$\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = - \sum_{k=1}^K y_k \log(\hat{y}_k).$$

2.1. Softmax como vector de probabilidades

Demuestre que la salida de softmax cumple:

$$\hat{y}_k > 0$$

para todo k , y que:

$$\sum_{k=1}^K \hat{y}_k = 1.$$

Explique por qué estas dos propiedades permiten interpretar $\hat{\mathbf{y}}$ como una distribución de probabilidad sobre las clases.

Solución:

Demostración de las propiedades:

1. Positividad ($\hat{y}_k > 0$):

Para cualquier $z_k \in \mathbb{R}$, la función exponencial satisface estrictamente $e^{z_k} > 0$. Dado que la suma de términos estrictamente positivos también es positiva, la suma del denominador cumple:

$$\sum_{j=1}^K e^{z_j} > 0.$$

El cociente entre dos números reales estrictamente positivos resulta en un valor estrictamente positivo:

$$\hat{y}_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}} > 0, \quad \forall k \in \{1, \dots, K\}.$$

2. Suma unitaria ($\sum_{k=1}^K \hat{y}_k = 1$):

Sumando la expresión de $\hat{y}_k$ sobre todas las K clases:

$$\sum_{k=1}^K \hat{y}_k = \sum_{k=1}^K \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}$$

Puesto que el denominador $\sum_{j=1}^K e^{z_j}$ no depende del índice de la suma externa k , se puede extraer como un factor común:

$$\sum_{k=1}^K \hat{y}_k = \frac{1}{\sum_{j=1}^K e^{z_j}} \sum_{k=1}^K e^{z_k} = \frac{\sum_{k=1}^K e^{z_k}}{\sum_{j=1}^K e^{z_j}} = 1.$$

Interpretación probabilística:

- La condición $\hat{y}_k > 0$ garantiza no negatividad en las asignaciones de probabilidad para cada evento elemental.
- La condición $\sum_{k=1}^K \hat{y}_k = 1$ asegura la normalización del espacio muestral completo.

Ambas propiedades combinadas acotan cada componente al intervalo $(0, 1)$, permitiendo interpretar formalmente a cada $\hat{y}_k$ como la probabilidad condicional predicha $P(y = k \mid \mathbf{x})$ sobre un conjunto de K clases mutuamente excluyentes y exhaustivas.

2.2. Reducción a la clase correcta

Suponga que la clase correcta es c . Entonces el vector one-hot cumple:

$$y_c = 1, \quad y_k = 0 \text{ para } k \neq c.$$

Muestre que la pérdida se reduce a:

$$\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = -\log(\hat{y}_c).$$

Explique el significado de esta expresión en palabras.

Solución:

Demostración algebraicamente:

Partiendo de la definición general de la entropía cruzada categórica:

$$\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = -\sum_{k=1}^K y_k \log(\hat{y}_k)$$

Descomponiendo la suma en el término de la clase correcta c y los términos de las demás clases $k \neq c$:

$$\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = -\left(y_c \log(\hat{y}_c) + \sum_{k \neq c} y_k \log(\hat{y}_k) \right)$$

Sustituyendo los valores del vector one-hot ($y_c = 1$ y $y_k = 0$ para todo $k \neq c$):

$$\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = - \left((1) \log(\hat{y}_c) + \sum_{k \neq c} (0) \log(\hat{y}_k) \right)$$
$$\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = -\log(\hat{y}_c).$$

Significado de la expresión:

La pérdida de entropía cruzada multiclase para una muestra individual depende de forma exclusiva de la probabilidad que el modelo le asigna a la clase verdadera ($\hat{y}_c$). Las demás clases no aportan directamente a la pérdida porque su etiqueta y_k es cero. Así, el objetivo del entrenamiento se reduce a maximizar la probabilidad predicha para la clase correcta, lo cual minimiza $-\log(\hat{y}_c)$.

2.3. Cálculo e interpretación numérica

Considere un problema con tres clases:

$$K = 3.$$

La clase correcta es la segunda, por lo que:

$$\mathbf{y} = (0, 1, 0).$$

Calcule la pérdida para las siguientes predicciones:

$$\hat{\mathbf{y}}^{(A)} = (0, 1, 0, 8, 0, 1),$$

$$\hat{\mathbf{y}}^{(B)} = (0, 7, 0, 1, 0, 2),$$

$$\hat{\mathbf{y}}^{(C)} = (0, 3, 0, 4, 0, 3).$$

Luego ordene los tres casos de menor a mayor pérdida y explique el resultado.

Solución:

Cálculo de pérdidas:

Usando la simplificación $\mathcal{L}(\mathbf{y}, \hat{\mathbf{y}}) = -\ln(\hat{y}_2)$ para la segunda clase ($c = 2$):

- **Caso A:** $\mathcal{L}_A = -\ln(0,8) \approx 0,2231$
- **Caso B:** $\mathcal{L}_B = -\ln(0,1) \approx 2,3026$
- **Caso C:** $\mathcal{L}_C = -\ln(0,4) \approx 0,9163$

Ordenamiento de menor a mayor pérdida:

$$\mathcal{L}_A < \mathcal{L}_C < \mathcal{L}_B \quad (0,2231 < 0,9163 < 2,3026)$$

Explicación del resultado:

El orden obtenido refleja directamente el valor de la probabilidad asignada a la clase correcta ($\hat{y}_2$):

- **Caso A** asigna la probabilidad más alta ($\hat{y}_2 = 0,8$) a la clase verdadera, por lo que su pérdida es la más baja.
- **Caso C** asigna una probabilidad intermedia ($\hat{y}_2 = 0,4$), lo que genera una pérdida moderada.
- **Caso B** asigna una probabilidad muy baja ($\hat{y}_2 = 0,1$) a la clase real, resultando en la pérdida más alta por estar fuertemente equivocado.

2.4. Derivada guiada de softmax + entropía cruzada

Queremos derivar la pérdida respecto a cada logit z_j . Partimos de:

$$\mathcal{L} = - \sum_{k=1}^K y_k \log(\hat{y}_k),$$

con

$$\hat{y}_k = \frac{e^{z_k}}{\sum_{r=1}^K e^{z_r}}.$$

Primero muestre que:

$$\log(\hat{y}_k) = z_k - \log\left(\sum_{r=1}^K e^{z_r}\right).$$

Luego sustituya esta expresión en la pérdida y use que:

$$\sum_{k=1}^K y_k = 1.$$

A partir de ello, derive respecto a z_j y muestre que:

$$\frac{\partial \mathcal{L}}{\partial z_j} = \hat{y}_j - y_j.$$

Finalmente, escriba el resultado vectorial:

$$\nabla_{\mathbf{z}} \mathcal{L} = \hat{\mathbf{y}} - \mathbf{y}.$$

Solución:

1. Expansión del logaritmo de softmax:

Aplicando la propiedad del logaritmo de un cociente $\log(a/b) = \log(a) - \log(b)$:

$$\log(\hat{y}_k) = \log\left(\frac{e^{z_k}}{\sum_{r=1}^K e^{z_r}}\right) = \log(e^{z_k}) - \log\left(\sum_{r=1}^K e^{z_r}\right)$$

Puesto que $\log(e^{z_k}) = z_k$:

$$\log(\hat{y}_k) = z_k - \log\left(\sum_{r=1}^K e^{z_r}\right).$$

2. Sustitución e inserción de la condición de suma unitaria:

Sustituyendo $\log(\hat{y}_k)$ en la función de pérdida:

$$\mathcal{L} = - \sum_{k=1}^K y_k \left(z_k - \log \left(\sum_{r=1}^K e^{z_r} \right) \right)$$

Distribuyendo el sumatorio:

$$\mathcal{L} = - \sum_{k=1}^K y_k z_k + \sum_{k=1}^K y_k \log \left(\sum_{r=1}^K e^{z_r} \right)$$

Como el término $\log \left(\sum_{r=1}^K e^{z_r} \right)$ no depende del índice k , sale como factor común:

$$\mathcal{L} = - \sum_{k=1}^K y_k z_k + \log \left(\sum_{r=1}^K e^{z_r} \right) \sum_{k=1}^K y_k$$

Usando la condición de que $\sum_{k=1}^K y_k = 1$:

$$\mathcal{L} = - \sum_{k=1}^K y_k z_k + \log \left(\sum_{r=1}^K e^{z_r} \right).$$

3. Derivación respecto al logit z_j :

Calculando la derivada parcial con respecto a z_j :

$$\frac{\partial \mathcal{L}}{\partial z_j} = \frac{\partial}{\partial z_j} \left(- \sum_{k=1}^K y_k z_k \right) + \frac{\partial}{\partial z_j} \left(\log \left(\sum_{r=1}^K e^{z_r} \right) \right)$$

- Para la primera suma, el único término que depende de z_j ocurre cuando $k = j$:

$$\frac{\partial}{\partial z_j} \left(- \sum_{k=1}^K y_k z_k \right) = -y_j.$$

- Para el término logarítmico, aplicando la regla de la cadena:

$$\frac{\partial}{\partial z_j} \left(\log \left(\sum_{r=1}^K e^{z_r} \right) \right) = \frac{1}{\sum_{r=1}^K e^{z_r}} \cdot \frac{\partial}{\partial z_j} \left(\sum_{r=1}^K e^{z_r} \right) = \frac{e^{z_j}}{\sum_{r=1}^K e^{z_r}} = \hat{y}_j.$$

Sumando ambos componentes:

$$\frac{\partial \mathcal{L}}{\partial z_j} = \hat{y}_j - y_j.$$

4. Resultado vectorial:

Agrupando la derivada parcial para cada componente $j \in \{1, \dots, K\}$ en el vector gradiente:

$$\nabla_{\mathbf{z}} \mathcal{L} = \left(\frac{\partial \mathcal{L}}{\partial z_1}, \frac{\partial \mathcal{L}}{\partial z_2}, \dots, \frac{\partial \mathcal{L}}{\partial z_K} \right) = (\hat{y}_1 - y_1, \hat{y}_2 - y_2, \dots, \hat{y}_K - y_K)$$

$$\nabla_{\mathbf{z}} \mathcal{L} = \hat{\mathbf{y}} - \mathbf{y}.$$

2.5. Interpretación de la señal de error multiclase

Interprete el resultado:

$$\hat{\mathbf{y}} - \mathbf{y}.$$

Explique qué ocurre:

- En la componente correspondiente a la clase correcta.
- En las componentes correspondientes a clases incorrectas.
- Cuando el modelo asigna mucha probabilidad a una clase equivocada.

Solución:

La expresión $\hat{\mathbf{y}} - \mathbf{y}$ nos da directamente el gradiente de la pérdida respecto a los logits. Esta señal es muy elegante porque nos dice exactamente hacia dónde y con qué fuerza deben ajustarse los valores de la red antes de pasar por la función softmax.

Veamos qué pasa en cada caso:

a. En la clase correcta ($y_c = 1$):

La señal de error toma la forma $\hat{y}_c - 1$. Como la probabilidad predicha $\hat{y}_c$ siempre será un número entre 0 y 1, esta resta siempre da un valor **negativo**. En optimización (por descenso de gradiente), un gradiente negativo indica que debemos **aumentar** el logit correspondiente. Es decir, el modelo recibe la instrucción directa de "subir" la puntuación de la clase correcta.

b. En las clases incorrectas ($y_k = 0$):

Para cualquier clase que no sea la real, la etiqueta es cero. La señal queda como $\hat{y}_k - 0 = \hat{y}_k$. Al ser una probabilidad, este valor siempre es **positivo**. Un gradiente positivo le indica al optimizador que debe **disminuir** el logit. Básicamente, el algoritmo está suprimiendo activamente las puntuaciones de todas las clases que no son la respuesta correcta.

c. Al asignar mucha probabilidad a una clase equivocada:

Si el modelo se equivoca con mucha confianza (por ejemplo, predice $\hat{y}_k = 0,9$ para una clase donde $y_k = 0$), el gradiente en esa componente será un valor positivo grande (0,9). Esto genera un castigo fuerte: el algoritmo reducirá drásticamente el logit de esa clase equivocada en la siguiente actualización.

En paralelo, como el softmax suma 1, la clase correcta obligatoriamente se habrá quedado con una probabilidad bajísima (digamos $\hat{y}_c = 0,1$), lo que genera un gradiente muy negativo ($0,1 - 1 = -0,9$). Esto fuerza un aumento rápido y agresivo del logit de la clase correcta. En resumen, una equivocación confiada provoca una corrección drástica en ambas direcciones al mismo tiempo.

3. Conexiones conceptuales con lo visto en clase

Responda de manera argumentada. No se espera una respuesta extensa, pero sí precisa. Use fórmulas cuando le ayuden a sostener su argumento.

3.1. MSE, identidad y regresión

Explique por qué la combinación

salida identidad + MSE

es natural para problemas de regresión.

En su respuesta, aclare qué interpretación tiene $\hat{y}$ en regresión.

Solución:

Interpretación de $\hat{y}$:

En regresión ($y \in \mathbb{R}$), la salida $\hat{y}$ representa la estimación de la media condicional de la variable respuesta:

$$\hat{y} = \mathbb{E}[y \mid \mathbf{x}].$$

Justificación de la combinación:

- **Identidad** ($f(z) = z$): No acota la salida, permitiendo predecir cualquier valor en la recta real $\mathbb{R}$.
- **MSE**: Surge de maximizar la verosimilitud (MLE) bajo el supuesto de errores Gausianos ($y \mid \mathbf{x} \sim \mathcal{N}(\hat{y}, \sigma^2)$).
- **Gradiente**: Su combinación genera la señal de error directa $\frac{\partial \mathcal{L}}{\partial z} = \hat{y} - y$, asegurando un aprendizaje estable sin saturación.

3.2. Sigmoid, softmax y clasificación probabilística

Compare brevemente

sigmoid + BCE

con

softmax + CCE.

Explique en qué tipo de problema se usa cada combinación y qué representa la salida del modelo.

Solución:

▪ Sigmoid + BCE (Binary Cross-Entropy):

- **Uso**: Clasificación binaria o multietiqueta (donde las clases no son mutuamente excluyentes).
- **Salida**: Un valor $\hat{y} \in (0, 1)$ que representa la probabilidad Bernoulli independiente $P(y = 1 \mid \mathbf{x})$.

▪ Softmax + CCE (Categorical Cross-Entropy):

- **Uso**: Clasificación multiclase con $K > 2$ clases mutuamente excluyentes.
- **Salida**: Un vector de probabilidades $\hat{\mathbf{y}} \in (0, 1)^K$ normalizado tal que $\sum_{k=1}^K \hat{y}_k = 1$, donde cada componente representa $P(y = k \mid \mathbf{x})$.

3.3. Perceptrón frente a clasificación probabilística

En el perceptrón, la salida es una decisión dura:

$$\hat{y} \in \{-1, +1\}.$$

En clasificación probabilística, la salida es una probabilidad.

Explique por qué esta diferencia permite construir funciones de pérdida diferenciables como la entropía cruzada, mientras que la regla del perceptrón se basa en una actualización correctiva cuando hay mala clasificación.

Solución:

- **Decisión dura del Perceptrón:** Utiliza una función de activación no suave (como la función escalón $\text{signo}(z)$), cuya derivada es cero en casi todas partes e indefinida en el origen ($z = 0$). Al no tener un gradiente informativo ($\nabla_z \hat{y} = 0$), es imposible aplicar algoritmos basados en gradiente continuo (como descenso de gradiente por retropropagación). Por ende, el perceptrón depende de una regla heurística de actualización discreta que solo se activa tras cometer un error de clasificación.
- **Salida probabilística y diferenciabilidad:** Al usar funciones suaves y acotadas como la sigmoide o softmax ($\hat{y} \in (0, 1)$), la salida varía de forma continua respecto a los parámetros. Esto genera una superficie de pérdida suave (como la entropía cruzada) con gradientes no nulos e informativos ($\frac{\partial \mathcal{L}}{\partial z} = \hat{y} - y$), permitiendo cuantificar la incertidumbre del modelo y optimizar mediante descenso de gradiente.

3.4. Pérdida y optimizador no son lo mismo

Explique la diferencia entre función de pérdida y optimizador. Use en su respuesta al menos dos de los siguientes términos: MSE, entropía cruzada, SGD, momentum, Adam.

Solución:

- **Función de pérdida (el "qué medir"):** Es un criterio matemático escalar que evalúa qué tan buenas o malas son las predicciones del modelo en comparación con los valores reales. Define la superficie de error a minimizar (por ejemplo, **MSE** para regresión o **entropía cruzada** para clasificación).
- **Optimizador (el "cómo ajustar"):** Es el algoritmo encargado de actualizar los pesos y sesgos del modelo en la dirección opuesta al gradiente para reducir la función de pérdida. Determina la estrategia de aprendizaje y la magnitud de los pasos (por ejemplo, **SGD**, **SGD con momentum** o **Adam**).

3.5. Por qué la señal $\hat{y} - y$ es importante

Tanto en el caso sigmoid + BCE como en softmax + CCE aparece una señal de salida de la forma

$$\hat{y} - y$$

o, en forma vectorial,

$$\hat{\mathbf{y}} - \mathbf{y}.$$

Explique por qué este resultado es importante para el entrenamiento de redes neuronales y cómo anticipa la idea de *backpropagation*.

Solución:

- **Importancia para el entrenamiento:** La señal $\hat{\mathbf{y}} - \mathbf{y}$ representa el residuo directo entre la predicción y el valor real. Al combinar la activación adecuada con su pérdida natural (como softmax con entropía cruzada), el término de saturación derivado de la activación se cancela algebraicamente. Esto evita el problema de desvanecimiento del gradiente en la capa de salida, haciendo que el aprendizaje sea directamente proporcional al error cometido (a mayor error, mayor gradiente).
- **Anticipación de *backpropagation*:** Por la regla de la cadena, el gradiente respecto a cualquier peso interno w_{ij} se compone multiplicativamente comenzando desde la capa final:

$$\frac{\partial \mathcal{L}}{\partial w_{ij}} = \frac{\partial \mathcal{L}}{\partial \mathbf{z}} \cdot \frac{\partial \mathbf{z}}{\partial w_{ij}} = (\hat{\mathbf{y}} - \mathbf{y}) \cdot \frac{\partial \mathbf{z}}{\partial w_{ij}}.$$

La señal $\hat{\mathbf{y}} - \mathbf{y}$ actúa como la **condición de frontera** o punto de partida del algoritmo de retropropagación. Representa la "fuente" del error desde la cual el gradiente se propaga hacia atrás, capa por capa, mediante multiplicaciones de matrices de pesos y derivadas locales.

Observación final

El objetivo de esta parte no es memorizar fórmulas, sino entender cómo cambia el entrenamiento cuando cambia el tipo de problema. En regresión, la salida del modelo representa un valor numérico. En clasificación, la salida representa una probabilidad o una distribución de probabilidades. Esa diferencia obliga a escoger funciones de pérdida distintas y cambia la forma de la señal de error que se propaga durante el entrenamiento.